Organização e Recuperação da Informação

Programa do curso Introdução



Objetivos

 Apresentar as principais técnicas para armazenamento, recuperação, ordenação e garantia de segurança de dados em memória secundária.



Em outras palavras

 Noções de implementação de banco de dados e/ou recuperação de dados em arquivos



Ementa

- Dispositivos externos de armazenamento.
- Representação e manipulação de dados em memória secundária.
- Organização e estrutura de arquivos.
- Classificação externa.
- Técnicas de compressão de dados.
- Introdução à criptografia.
- Noções de complexidade dos algoritmos estudados.

Referências

- ZIVIANI, N. Projeto de algoritmos com implementação em Pascal e C. 2 ed. Thomson Pioneira, 2004. 572 p.
- GARCIA-MOLINA, H. et al. Implementação de Sistemas de Banco de Dados. Tradução de Vandenberg D. de Souza. Rio de Janeiro: Campus, 2001.
- TENENBAUM, A. M., LANGSAM, Y., AUGENSTEIN M. J., Estruturas de Dados Usando C. 1 ed. Makron Books, 1995. 904 p.
- KNUTH, D. E. The art of computer programming: sorting and searching. 2.ed. vol 3. Hardcover, 1998.
- THARP, A. L. File Organization and Processing. John Willey & Sons, Inc. 1988.



Recursos de Programação

- Busque por:
 - Programação em C





Dados

- Prof. Leard O. Fernandes
 - lofernandes@uesc.br
 - Enviar email solicitando entrada no grupo
- Dados do Curso
 - Dias
 - Terças: 16:50-18:30
 - Quintas: 16:50-18:30
 - Local
 - Laboratório: 17B



Metodologia Avaliação

- Frequência (Aulas 100% presenciais)
 - Mínimo de 75%
- 03 Atividades Avaliativas
 - 1 Crédito:
 - Atividades
 - 2 Créditos: 02 Avaliações
 - /2017
 - /2017
- Exame Final
 - À definir



Introdução

Introdução

Dispositivos de Armazenamento

Organização e Recuperação da Informação

- Abrange diversas subáreas da computação:
 - Arquitetura de Computadores,
 - Sistemas Operacionais,
 - Estrutura de Dados,
 - Banco de Dados,
 - ...
- O foco da nossa disciplina será no armazenamento e recuperação de dados em dispositivos secundários.



Armazenamento de dados

- O armazenamento de dados do PC, é o meio pelo qual o computador registra e acessa dados digitais para processamento.
- Ele permite que os computadores conservem as informações e que elas possam ser acessadas pelos programas e usuários.



Armazenamento de dados

- Como um sistema computacional armazena e gerencia um grande volume de dados?
- Quais as melhores representações e estruturas de dados que suportam manipulações eficientes destes dados?

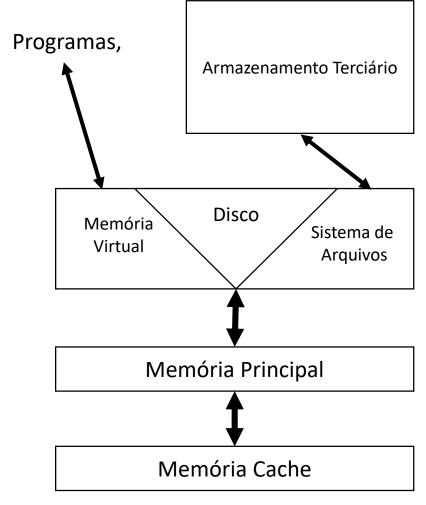


Hierarquia de Memória

- Um sistema computacional típico possui um conjunto de diferentes componentes em que os dados podem ser armazenados
- Estes componentes possuem variação em:
 - · Capacidade,
 - Velocidade, e
 - Custo.



Hierarquia de Memória





Leard de Oliveira Fernandes CET 082

Armazenamento Primário

- O armazenamento primário refere-se aos recursos de hardware que são rapidamente acessíveis e utilizados no armazenamento de dados para processamento imediato.
- Entre os mecanismos de armazenamento primário, os principais são:
 - Memória Cache
 - Memória Principal



Armazenamento Secundário

- No armazenamento secundário estão os dados que não são imediatamente acessíveis pela CPU.
- Os dados são armazenados até serem excluídos ou sobrescritos pelos programas e/ou usuário.
 - Discos Rígidos
 - Magnéticos,
 - Eletrônicos



Dispositivos Magnéticos



- São os mais antigos e mais utilizados atualmente
- Permitem uma grande densidade de informação
- Baixo custo
- Passaram por diversas evoluções ao longo dos anos
- Dispositivos Mecânicos
- Versões hibridas (magnético + eletrônico)
- 826 GB/in²
- 140MB/s
- \$0.032/GB



Dispositivos Eletrônicos

- Tecnologia também é conhecida como unidade de estado sólido ou SSD (solid state drive) para armazenamento não volátil.
- Não possuem partes móveis, apenas circuitos eletrônicos;
- Ciclo de vida da célula é reduzida
- Capacidade: 120GB ~ 512GB (16TB)
- 100-600MB/s
- \$0.37/GB





- https://en.wikipedia.org/wiki/Hard disk drive
- https://en.wikipedia.org/wiki/Solid-state drive



- Apesar do aumento de densidade de armazenamento de um único disco é necessário que exista uma maior segurança nos dados armazenados
 - Se um disco falha e não seja possível recuperar os dados?
- Uma boa ideia seria utilizar diversos discos
 - Proporciona um aumento na capacidade de armazenamento;
 - Se usado corretamente, pode prover um armazenamento seguro.



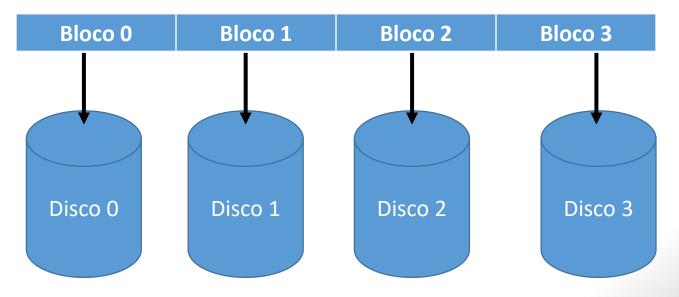
- O RAID (Redundant Array of Independent Disks, Conjunto redundante de discos independentes) implementa essa ideia,
 - Se chamava conjunto redundante de discos baratos (Redudant Array of Inexpensive Disks)
- Conectando múltiplos discos para disponibilizar:
 - Aumento de capacidade
 - Rápido Acesso a leitura de dados
 - Dados redundantes



- Existem diferentes níveis de sistemas RAID
 - Diferentes níveis de redundância,
 - Checagem de erro,
 - Capacidade,
 - E custo.



- Divisão (striping)
 - Dado um arquivo de dados, o mesmo será mapeado em diferentes discos
 - Torna possível a leitura paralela





Byte	Bits 1	Par	Ímpar
10110001			
10111001			

- Paridade (parity)
 - Forma de realizar a checagem de erro e sua correção
- Existem dois tipos de paridade
 - Paridade Par
 - Conte o número de ocorrências de bit 1 na sequência, se o número for ímpar, é adicionado o valor 1 ao final da cadeia de dados, tornando o número de bits par, caso contrário adicione o valor 0. A quantidade total de bits 1 deve ser par.
 - Paridade Ímpar
 - Conte o número de ocorrência de bit 1 na sequência de dados, se o número for par, é adicionado o valor 1 ao final da cadeira de dados, tornando o número de bits ímpar. Caso contrário, adicione o valor 0. A quantidade total de bits 1 deve ser ímpar.



Byte	Bits 1	Par	Ímpar
10110001	4	10110001 0	10110001 1
10111001	5	10111001 1	10111001 0

- Paridade (parity)
 - Forma de realizar a checagem de erro e sua correção
- Existem dois tipos de paridade
 - Paridade Par
 - Conte o número de ocorrências de bit 1 na sequência, se o número for ímpar, é adicionado o valor 1 ao final da cadeia de dados, tornando o número de bits par, caso contrário adicione o valor 0. A quantidade total de bits 1 deve ser par.
 - Paridade Ímpar
 - Conte o número de ocorrência de bit 1 na sequência de dados, se o número for par, é adicionado o valor 1 ao final da cadeira de dados, tornando o número de bits ímpar. Caso contrário, adicione o valor 0. A quantidade total de bits 1 deve ser ímpar.



- Espelhamento (mirroring)
- Mantém uma cópia dos dados em dois discos separados;
- Se algum dado é perdido, ele pode ser recuperado
- É caro
 - Requer o dobro de discos
- A operação de escrita pode ser lenta
 - Duas escritas
- Leitura é otimizada
 - É possível realizar a leitura de um arquivo em paralelo



- RAID por Software
 - O próprio sistema operacional é responsável por implementar o sistema de gerenciamento do RAID
- RAID por Hardware
 - Dispositivo dedicado, que realiza o gerenciamento do RAID;
 - O seu gerenciamento não é transparente ao S.O., o que o torna como um "simples" disco;



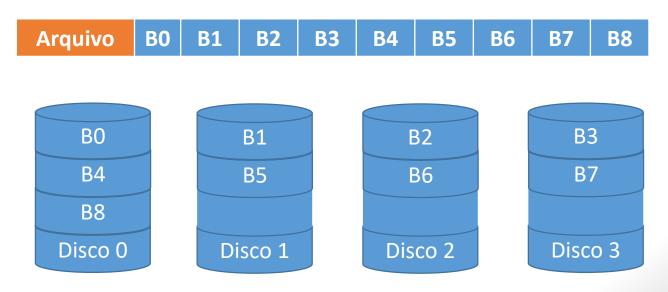
- Todos tipos de RAID
 - Se comportam como único disco virtual para o sistema;
 - Todos os RAIDs possuem a propriedade de que os dados sejam distribuídos sobre os discos;
 - Permitem operações em paralelo
- Vários padrões foram definidos por Patterson, et al.
- Atualmente existem 7 padrões de configuração RAID
 - Níveis: 0, 1, 2, 3, 4, 5 e 6
- Existem outros níveis, mas não são padronizados



29

RAID Nível O

- Também conhecido como RAID divisão, o RAID 0 divide os dados entre dois ou mais discos
- Não provê tolerância a falhas ou redundância
- A falha num disco, leva uma falha total do sistema

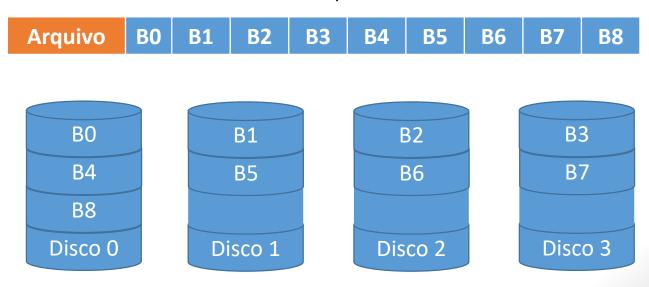




Leard de Oliveira Fernandes CET 082

RAID Nível O

- A principal vantagem deste nível é a performance de leitura dos dados
- Pode ser criado com tamanhos de discos diferentes
 - O tamanho total será a quantidade de disco vezes o tamanho do disco de menor tamanho
 - O excedente é desconsiderado;





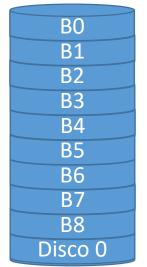
Leard de Oliveira Fernandes CET 082

RAID Nível 1

 Consiste de uma cópia exata, ou espelho, do conjunto de dados sobre dois ou mais discos;

CET 082

- Esta configuração não oferece
 - Paridade,
 - Se usar somente dois discos não há divisão
 - Acima de dois discos é possível realizar divisão







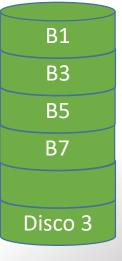
RAID Nível 1

- Consiste de uma cópia exata, ou espelho, do conjunto de dados sobre dois ou mais discos;
- Esta configuração não oferece
 - Paridade,
 - Se usar somente dois discos não há divisão
 - Acima de dois discos é possível realizar divisão





CET 082





RAID Nível 2

- Raramente utilizado na prática
- Não trabalha com faixas de setores, e sim com palavras (conjunto de bits/bytes);
- A ideia era quebrar cada byte num conjunto de 4 bits cada, e adicionar mais 3 bits (código de hamming);
- Cada disco precisa estar sincronizado na mesma posição do braço e rotação;
- Assim, utilizando 7 bits, seria necessário 7 discos, onde cada bit seria escrito num disco equivalente;



RAID Nível 3

- Raramente utilizado na prática
- Versão simplificada do RAID 2, onde um único bit de paridade é computado para cada palavra de dados, e armazenado num disco de paridade;
- É necessário que os discos estejam perfeitamente sincronizados;



RAID Nível 4

- Semelhante ao RAID nível 0;
- Possui paridade entre os blocos, escritos num disco de paridade;
- Todos os blocos são processados juntos, usando a operação de ou exclusivo;
- Se um disco quebrar é possível encontrar os bytes perdidos a partir do disco de paridade e da leitura de todos os blocos





Leard de Oliveira Fernandes
CET 082

RAID Nível 4

 Apesar de funcionar bem para a perca de um disco, é ineficiente para atualizações pequenas e constantes; 36

- Se setor/bloco sofre alteração é necessário ler todos os discos para atualizar a paridade, sendo esta reescrita;
- Existe gargalo na escrita, por conta do disco de paridade;
 - Escrita em B0 e B1, B6 e B7 podem ocorrer em paralelo
 - Mas a atualização de P0-3 e P4-7 deverão ser sequenciais;



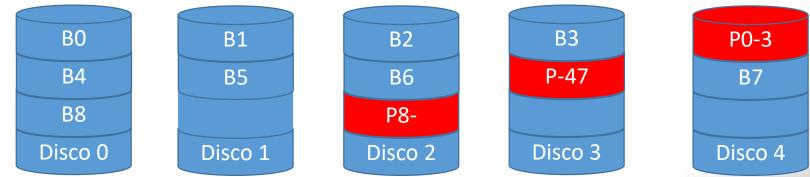


Leard de Oliveira Fernandes CET 082

RAID Nível 5

 Em função do gargalo que o RAID 4 possui, a distribuição uniforme dos bits de paridade nos discos remove este gargalo; 37

- Escrita em BO, B1, B6 e B7 não geram gargalos!!
- Em contrapartida, a recuperação dos dados no caso de uma falha de disco é mais complexa de ser gerenciada;

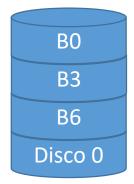


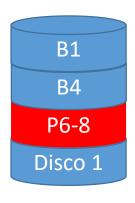


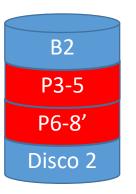
Leard de Oliveira Fernandes
CET 082

RAID Nível 6

- Semelhante ao RAID 5
- No RAID 6, é inserido um bloco de paridade adicional;
- Os blocos são divididos, e utilizam dois blocos de paridade;
- Este recurso visa aumentar a segurança na recuperação dos dados caso ocorra a falha em mais de um disco;
- Diminui a eficiência da escrita, comparado ao RAID 5, já que precisa escrever em dois discos diferentes a paridade;













Leard de Oliveira Fernandes
CET 082